

Universidades de Burgos, León y  
Valladolid

Máster universitario

# Inteligencia de Negocio y Big Data en Entornos Seguros



TFM del Máster Inteligencia de Negocio  
y Big Data en Entornos Seguros

Clasificación del iris

Presentado por Ignacio Ponsoda Llorens  
en Universidad de Burgos — 13 de enero  
de 2022

Tutor: Dr. José Francisco Díez Pastor y Dr.  
Pedro Latorre Carmona



# Universidades de Burgos, León y Valladolid



## Máster universitario en Inteligencia de Negocio y Big Data en Entornos Seguros

D. nombre tutor, profesor del departamento de nombre departamento, área de nombre área.

Expone:

Que el alumno Ignacio Ponsoda Llorens, con DNI 21698927Z, ha realizado el Trabajo final de Máster en Inteligencia de Negocio y Big Data en Entornos Seguros titulado título de TFM.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 13 de enero de 2022

Vº. Bº. del Tutor:

Vº. Bº. del co-tutor:

D. nombre tutor

D. nombre co-tutor





## **Resumen**

Cada vez se utilizan más elementos biomédicos para poder identificar a las personas. En este trabajo vamos a utilizar técnicas de Inteligencia Artificial para segmentar el iris y hacer una clasificación del mismo, optimizando procesos anteriores y haciendolos reproducibles.

## **Descriptores**

Palabras separadas por comas que identifiquen el contenido del proyecto Ej: servidor web, buscador de vuelos, android . . .

### **Abstract**

A **brief** presentation of the topic addressed in the project.

### **Keywords**

keywords separated by commas.



---

# Índice general

---

Índice general	iii
Índice de figuras	vi
Índice de tablas	vii
 <b>Memoria</b>	 <b>1</b>
<b>1. Introducción</b>	<b>3</b>
1.1. Outline . . . . .	3
<b>2. Objetivos del proyecto</b>	<b>5</b>
<b>3. Conceptos teóricos</b>	<b>7</b>
3.1. Elementos biométricos . . . . .	7
3.2. Dataset CASIA . . . . .	7
3.3. Preprocesamiento . . . . .	8
3.4. Data augmentation . . . . .	9
3.5. Fine tuning . . . . .	10
3.6. Referencias . . . . .	10
3.7. Imágenes . . . . .	10
3.8. Listas de items . . . . .	10
3.9. Tablas . . . . .	11
<b>4. Técnicas y herramientas</b>	<b>13</b>
4.1. Dataset . . . . .	13
4.2. Redes neuronales preentrenadas . . . . .	13

4.3. Github . . . . .	13
4.4. Python . . . . .	13
4.5. Scrum . . . . .	14
4.6. Recursos . . . . .	14
<b>5. Aspectos relevantes del desarrollo del proyecto</b>	<b>15</b>
5.1. Optimización de los notebooks previos . . . . .	15
5.2. Data agumentation . . . . .	16
5.3. Clasificación de las imágenes . . . . .	17
<b>6. Trabajos relacionados</b>	<b>19</b>
<b>7. Conclusiones y Líneas de trabajo futuras</b>	<b>21</b>
7.1. Conclusiones . . . . .	21
7.2. Líneas de trabajo futuras . . . . .	21
<b>Apéndices</b>	<b>22</b>
<b>Apéndice A Plan de Proyecto Software</b>	<b>25</b>
A.1. Introducción . . . . .	25
A.2. Planificación temporal . . . . .	25
A.3. Estudio de viabilidad . . . . .	25
<b>Apéndice B Especificación de Requisitos</b>	<b>27</b>
B.1. Introducción . . . . .	27
B.2. Objetivos generales . . . . .	27
B.3. Catalogo de requisitos . . . . .	27
B.4. Especificación de requisitos . . . . .	27
<b>Apéndice C Especificación de diseño</b>	<b>29</b>
C.1. Introducción . . . . .	29
C.2. Diseño de datos . . . . .	29
C.3. Diseño procedimental . . . . .	29
C.4. Diseño arquitectónico . . . . .	29
<b>Apéndice D Documentación técnica de programación</b>	<b>31</b>
D.1. Introducción . . . . .	31
D.2. Estructura de directorios . . . . .	31
D.3. Manual del programador . . . . .	31
D.4. Compilación, instalación y ejecución del proyecto . . . . .	31
D.5. Pruebas del sistema . . . . .	31

<i>Índice general</i>	v
-----------------------	---

<b>Apéndice E Documentación de usuario</b>	<b>33</b>
E.1. Introducción . . . . .	33
E.2. Requisitos de usuarios . . . . .	33
E.3. Instalación . . . . .	33
E.4. Manual del usuario . . . . .	33
<b>Bibliografía</b>	<b>35</b>

---

# Índice de figuras

---

3.1. Ejemplo de una imagen del dataset CASIA . . . . .	8
5.2. Ejemplo de workflow del paper 05 techniques review . . . . .	16

---

# Índice de tablas

---

3.1. Herramientas y tecnologías utilizadas en cada parte del proyecto	11
---	----



# Memoria





---

# Introducción

---

El iris se utiliza como elemento de reconocimiento biométrico, tanto por su inmutabilidad a lo largo del tiempo como por resultar un valor único y personal, que supone que dos personas no tendrían el mismo iris (05 Iris Recognition Developmen Techniques: A Comprehensive Review).

En este estudio, se compararán técnicas de redes neuronales completas como una combinación de redes neuronales para la segmentación del ojo, la extracción de características y finalmente, con técnicas de Machine Learning.

Para ello, vamos a utilizar una red neuronal preentrenada de ImageNet a la que le aplicaremos fine-tuning y compararemos los resultados con la combinación de una red neuronal preentrenada para la segmentación, un preprocesamiento para extraer y normalizar el iris, la red preentrenada ImageNet para extraer las características principales (sin realizar fine-tuning) y machine learning para el cluster (identificación del individuo).

## 1.1. Outline

El resto del docuemnto se estructura de la siguiente manera. El capítulo 2 contiene los objetivos del proyecto. El capítulo 3 contiene los conceptos teóricos necesarios para entender el proyecto. El capítulo 4 muestra las técnicas y herramientas utilizadas en el desarrollo de este trabajo. En el capítulo 5 se muestran los Aspectos más relevantes que se han desarrollado. En el capítulo 6 los trabajos relacionados y en el capítulo 7 las conclusiones y las líneas de trabajo futuras.



---

## Objetivos del proyecto

---

Los objetivos del trabajo son principalmente tres:

- Optimizar el código del TFG y hacerlo reproducible.
- Aplicar data augmentation para comprobar la robustez del modelo.
- Comparar la utilización de una única red neuronal para reconocimiento de personas con la combinación de redes neuronales y machine learning.



---

# Conceptos teóricos

---

Explicación de la sección

## 3.1. Elementos biométricos

05 techniques review entre todos los elementos biometricos, como huellas, cara, iris, voz y , el iris recognition system (IRS) es el metodo con mayor eficiencia a la hora de determinar la identiidad de las personas, ya que el iris es el mismo a lo largo de la vida de una persona y es único, incluso entre gemelos. Esto es incluso utilizado en los procesos post-mortem para poder determinar la pertenencia del cuerpo 06 Post-mortem iris recognition. El iris humanos es un organo del ojo, que tiene como funciona controlar el tamaño de la pupila en función de la cantidad de luz que llega hasta este 06 Post-mortem iris recognition.

## 3.2. Dataset CASIA

El dataset de CASIA es un dataset que contiene x imágenes del iris

Se han hecho estas fotos a un total de x sujetos hechas de x e y manera.




Figura 3.1: Ejemplo de una imagen del dataset CASIA

### 3.3. Preprocesamiento

La fase de preprocesamiento es la fase en la que se extrae el iris de la imagen, puesto que, tal como indican diferentes estudios (referencia), la parte del iris es la que permite identificar a las personas.

#### Segmentación

Detección de las distintas zonas del ojo.

#### Normalización

Normalización del iris y desenrollamiento en coordenadas polares

## 3.4. Data augmentation

El data augmentation es un proceso común en el análisis de imágenes y de datos en general. En el caso de los procesos de entrenamiento de las redes neuronales es común la utilización de técnicas de data augmentation, principalmente por dos situaciones, aunque estas no son excluyentes:

- Número insuficiente de datos: en este caso, el data augmentation se aplica porque el dataset no es lo suficientemente grande como para conseguir unos resultados positivos en la creación de una red neuronal.
- Aumento de la robustez del modelo: el segundo supuesto principal por el cual se utiliza data augmentation es la utilización de elementos que añadan dificultades a la red neuronal para cumplir su propósito, lo cual permitirá una mayor robustez del modelo.

### Ruido gausseano

La primera de las técnicas de data augmentation utilizadas ha sido el ruido gausseano, también conocido como ruido blanco. Este ruido provoca que los píxeles de una imagen cambien su valor siguiendo una distribución gausseana.

### Transformaciones afines

Las transformaciones afines son transformaciones de las imágenes que conservan el paralelismo de sus líneas rectas y paralelas y de alguna forma simulan una nueva perspectiva para esta. En cuanto a los tipos de transformaciones afines encontramos las siguientes: transformación de identidad, escalamiento, traducción, inclinación (de X o Y), rotación.

**Transformación de identidad**

**Escalamiento**

**Traducción**

**Inclinación**

**Rotación**

### 3.5. Fine tuning

El fine tuning es una técnica que se utiliza para poder ajustar los parámetros de las redes neuronales preentrenadas a los necesarios en relación con el dataset con el que se trabaja.

### 3.6. Referencias

Las referencias se incluyen en el texto usando cite [2]. Para citar webs, artículos o libros [1].

### 3.7. Imágenes

Se pueden incluir imágenes con los comandos standard de L<sup>A</sup>T<sub>E</sub>X, pero esta plantilla dispone de comandos propios como por ejemplo el siguiente:

### 3.8. Listas de items

Existen tres posibilidades:

- primer item.
- segundo item.

1. primer item.
2. segundo item.

**Primer item** más información sobre el primer item.

**Segundo item** más información sobre el segundo item.

■



Herramientas	App	AngularJS	API REST	BD	Memoria
HTML5		X			
CSS3		X			
BOOTSTRAP		X			
JavaScript		X			
AngularJS		X			
Bower		X			
PHP			X		
Karma + Jasmine		X			
Slim framework			X		
Idiorm			X		
Composer			X		
JSON		X	X		
PhpStorm		X	X		
MySQL				X	
PhpMyAdmin				X	
Git + BitBucket		X	X	X	X
MikTeX					X
TeXMaker					X
Astah					X
Balsamiq Mockups		X			
VersionOne		X	X	X	X

Tabla 3.1: Herramientas y tecnologías utilizadas en cada parte del proyecto

### 3.9. Tablas

Igualmente se pueden usar los comandos específicos de  $\text{\LaTeX}$  o bien usar alguno de los comandos de la plantilla.



---

# Técnicas y herramientas

---

Explicación de la sección

## 4.1. Dataset

Se ha utilizado el dataset de CASIA para la imágenes de ojos.

## 4.2. Redes neuronales preentrenadas

Así mismo, se ha utilizado la red neuronal preentrenada Basada en U-Net y accesible desde <https://github.com/jus390/U-net-Iris-segmentation>, la cual ya había sido entrenada para la segmentación del iris.

Finalmente, para el último proceso del proyecto, se utiliza imagenet como red neuronal preentrenada central.

## 4.3. Github

Para el control de versiones y el seguimiento de fases del proyecto

## 4.4. Python

Además se ha utilizado python para todo el proyecto, esto quiere decir preprocesado, creación y utilización de redes neuronales y clasificación contécnicas de machine learning.

Entre las principales librerías utilizadas se encuentran:

- os, para el acceso a los directorios
- numpy, para trabajar con las imágenes a nivel de arrays
- scikit-image, para la transformación de las imágenes y el uso de dataset
- tensorflow, para la modificación de las redes neuronales
- keras, para el manejo de las redes neuronales
- matplotlib, para las gráficas

## Visual Studio

Tanto para la redacción de la memoria con latex como para el estudio.

### 4.5. Scrum

Scrum es un marco que ayuda a la organización de los equipos entorno a un proyecto, en base a Sprints de una determinada duración y permite una retroalimentación continua del proyecto, de forma que se asegura que el equipo trabaje en consonancia.

En el caso de este proyecto, se ha adecuado la metodología de Scrum para cuadrar reuniones semanales o bisemanales con los tutores del proyecto, estableciendo los sprints y los objetivos de cada sprint utilizando la plataforma Github.

### 4.6. Recursos

En cuanto a las herramientas que se han contado para realizar los entrenamientos de las redes neuronales, se ha contado con un ordenador portatil con un procesador i7, 12 gb de ram y una gráfica dedicada NVIDIA de 1 gb.

---

# Aspectos relevantes del desarrollo del proyecto

---

El proyecto se divide en una fase preliminar, consistente en la adecuación del código previo, correspondiente en el TFG el cual se ha hecho extensible en este trabajo y tres propuestas diferentes para la identificación biomédica de personas a través de una imagen de su ojo utilizando el iris como parte central de este reconocimiento.

## 5.1. Optimización de los notebooks previos

La primera fase trata de la optimización del código previo y la creación de un pipeline con una configuración que permitiese un mejor control de las funciones. Se han creado funciones correspondientes a cada una de las fases y se han encapsulado en forma de partes de una pipeline, con el único argumento de entrada de la configuración.




Figura 5.2: Ejemplo de workflow del paper 05 techniques review

## Pipeline y configuración

Así pues, esta configuración permite establecer cuales van a ser los parámetros de la pipeline, principalmente (aunque puede ser fácilmente extensible), la ubicación del directorio del dataset, el tamaño del dataset de entrenamiento para la creación de los modelos de redes neuronales o los valores de data augmentation que se aplican.

## 5.2. Data agumentation

También del data augmentation, en el cual se aplica tanto ruido gausseano (de 2.5, 5 y 7.5) como transformaciones afines (mat reflexion, mat scale, rotación y shear), siendo realizadas de forma aleatoria, con lo cual los supuestos pueden ser:

- Imagen sin data augmentation
- Imagen con ruido gausseano
- Imagen con transformaciones afines y
- Imagen con ruido gausseano y transformaciones afines. Este dataset será el base para todo el proyecto.

Las fases del pipeline anterior, y por lo tanto las funciones creadas en el pipeline son: 1.Tratar el dataset, de forma que las imágenes, distribuidas en distintos directorios, se guardan en uno solo. Posteriormente, se realiza en mezclado de las imágenes, el dataset se divide en dos partes, una que será utilizada en el proceso (70 por ciento) y, finalmente, se guarda una parte del dataset que será utilizada para obtener los resultados finales.

La segunda fase se trata de la elección de la mejor forma de clasificar las imágenes de entrada:

### 5.3. Clasificación de las imágenes

(añadir el tiempo de ejecución y el accuracy de cada uno de los procesos)

#### Preprocesamiento y Machine Learning

La propuesta en el TFG anterior, en la cual se realiza un preprocesamiento de las imágenes del dataset original. Este preprocesamiento consiste primer lugar en la segmentación de las imágenes del iris con una red neuronal preentrenada precisamente para realizar esta acción. En segundo lugar, se realiza una extracción del iris a través de una binarización de las partes del ojo y una extracción del iris, a la que se le aplica una normalización para que quede proyectado. La siguiente fase de esta primera propuesta es la extracción de características (quitándole las dos últimas capas a una red neuronal) de la imagen normalizada para posteriormente utilizar una red neuronal preentrenada con imagenet (de hecho 3 redes de la cual se elige la mejor). Posteriormente, estas características extraídas se pasan a modelos de ML, que son los que realizarán la clasificación.

#### Preprocesamiento y Deep Learning

La segunda propuesta es la utilización de una red neuronal de VGG16, preentrenada con imagenet, a la que se le aplica un fine tuning del dataset de CASIAV1 para que sea capaz de clasificar las imágenes de acuerdo a las clases establecidas en el dataset.

#### Deep Learning

La tercera propuesta se basa en la utilización del dataset, directo sin preprocesamiento, para la fase del fine tuning y su posterior clasificación (para la clasificación de imágenes en las fases que han sufrido preprocesamiento, le

deberían de pasar imágenes que primero hayan entrado al pipeline hasta la fase de normalización!!). (temporal) Los resultados arrojan un acierto mayor en el caso del preproceso + red neuronal, por lo que se puede concluir que, en base a los parámetros establecidos en este estudio, la utilización de una fase de preprocesamiento que elimine las partes que los estudios determinan no tan útiles para la clasificación humana (vease, todo aquello que no es parte del iris) y posteriormente utiliza el fine tuning para adecuar una red neuronal preentrenada a las clases de las que se compone el dataset.



---

## Trabajos relacionados

---

El principal apartado anterior se puede encontrar en el TFG de extracción del iris, en el cual se basa este trabajo, puesto se realiza a grandes rasgos todo lo relativo a la primera de las opciones del trabajo.

Sobre temas de extracción del iris encontramos 02 iris wavelet neural, donde se hace un preprocesamiento con extracción del iris utilizando Hough Transform y la normalización con Daugmands rubber. Luego, tras eliminar el ruido, la extracción se realiza con transformaciones de wavelet. Finalmente, se crea una red neuronal utilizando el mean-squared error para calcular los pesos en la red.

En 03 deep iris encontramos el desarrollo de técnicas de deep learning para el reconocimiento del iris basado en convolutional neural network residual, utilizando una red preentrenada de ResNet50 y fine-tuning, entrenado con una cross-entropy loss function (but they are not using data augmentation, they are using another dataset IIT Delhi dataset and they are not doing the preprocessing step).

In 13 ImageNet Deep CNN they use the ImageNet dataset with data augmentation, dropout to train a neural network to detect images of the feed (maybe we can remove it as it is not related with iris).

En 14 experimental deep convolutional iris recognition, utilizaron el dataset CASIA - 10000 y la arquitectura VGG-Net, lo cual realiza un PCA para extraer los elementos más característicos de las imágenes. Después utilizan algoritmos de clasificación para clasificar las imágenes, como el SVM (esto es similar al TFG) y consiguen unos porcentajes de reconocimiento muy altos.

05 techniques review habla de siete pasos en los que se divide un sistema de reconocimiento del iris, 1)adquisición, 2)preprocesamiento, 3)segmentación 4)normalización, 5)extracción de características, 6) selección de features únicos y característicos, 7)clasificación. Este paper también describe una falta de trabajos entorno a datasets de baja calidad (revisar para sacar más papers). El paper también realza que los sistemas de reconocimiento del iris (IRS) se vuelven poco efectivos cuando las imágenes tienen rotaciones or reflejos, algo que intentamos de mejorar en nuestro proceso, añadiendo ruido con el data augmentation.

Este mismo paper también comenta los distintos dataset utilizados para estos estudios de reconocimiento de iris, el tipo de ruido utilizado así como su método, los tipos de segmentación tradicional y actual utilizados (habitualmente con redes neuronales), técnicas de normalización y extracción de características, así como los tipos de accuracy de los métodos de iris recognition.

De Marsico et al. [44] utiliza también el dataset de casia V! (parece que también Susitha and Subban [81]) para medir el accuracy y Lozej et al. [176] junto con Unet para El iris segmentation.

(esto casi se podría quitar pues no es tanto el foco de nuestro trabajo) Varkarakis et al. [179] también utiliza una cnn para segmentar el iris

Bakshi et al. [72] utiliza filtro gausseano combinado con Hough detección de líneas pero nadie utiliza solo gausseano y/o transformaciones afines (al menos en este recopilatorio).

15 finetunning or raw utiliza técnicas de deep learning para clasificar imágenes de ojos de el casia iris 300 dataset, no utiliza data augmentation. Para segmentation utilizan una herramienta llamada OSIRIS y prueban deep learning, fine tuning y raw para ver que clasifica mejor. ( It is better to take the best-performing model trained on either general-purpose or face images and fine-tune it to iris recognition task, rather than train own network) from scratch.

Existen varios papers que utilizan fully CNN, y lo mismo para feature extraction.

.... (utilizando Machine learning y deep learning)

Y para el tema de clasificación de personas con el ojo, se ha encontrado.

Por otro lado, en temas de fine tuning con redes neuronales, se tiene

---

# Conclusiones y Líneas de trabajo futuras

---

Explicación de la sección

## 7.1. Conclusiones

Como conclusion de este proyecto, la utilización de técnicas de machine learning, contando con ordenadores de pocos recursos, demuestra que el preprocesamiento es necesario para centrar los procesos en los elementos de las imágenes verdaderamente importantes. Por otro lado, una vez que la imagen está preprocesada, la utilización de redes neuronales con fine tuning para clasificar las imágenes se ha resuelto como un mayor accuracy que el modelo que aplica machine learning en la última fase pero este último ha demostrado ser más rápido, por lo tanto, la utilización de una u otra técnica variará según los recursos que se tengan y el contexto en el que se vaya a utilizar (inmediatamente con que se necesiten los resultados).

## 7.2. Líneas de trabajo futuras

Las líneas de trabajo futuras se podrían determinar con la utilización de estas técnicas con nuevos datasets, consiguiendo un modelo lo suficientemente robusto que permitiese su utilización en un programa de escritorio, con una primera fase de fine tuning con imágenes del ojo del usuario y una segunda fase donde este se utilizase como método de seguridad para el acceso a ciertos documentos de los aparatos electrónicos.



# Apéndice



## *Apéndice A*

---

# **Plan de Proyecto Software**

---

**A.1. Introducción**

**A.2. Planificación temporal**

**A.3. Estudio de viabilidad**

Viabilidad económica

Viabilidad legal





## *Apéndice B*

---

# **Especificación de Requisitos**

---

- B.1. Introducción
- B.2. Objetivos generales
- B.3. Catalogo de requisitos
- B.4. Especificación de requisitos



## *Apéndice C*

---

# **Especificación de diseño**

---

- C.1. Introducción
- C.2. Diseño de datos
- C.3. Diseño procedimental
- C.4. Diseño arquitectónico



## *Apéndice D*

---

# **Documentación técnica de programación**

---

- D.1. Introducción
- D.2. Estructura de directorios
- D.3. Manual del programador
- D.4. Compilación, instalación y ejecución del proyecto
- D.5. Pruebas del sistema



## *Apéndice E*

---

# **Documentación de usuario**

---

- E.1. Introducción
- E.2. Requisitos de usuarios
- E.3. Instalación
- E.4. Manual del usuario





---

## Bibliografía

---

- [1] John R. Koza. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, 1992.
- [2] Wikipedia. Latex — wikipedia, la enciclopedia libre, 2015. [Internet; descargado 30-septiembre-2015].