

Universidades de Burgos, León y
Valladolid

Máster universitario

Inteligencia de Negocio y Big Data en Entornos Seguros



**TFM del Máster Inteligencia de Negocio
y Big Data en Entornos Seguros**

**Clasificación de individuos a
partir de imágenes oculares y
redes neuronales pre-entrenadas.**

Presentado por Ignacio Ponsoda Llorens
en Universidad de Burgos — 11 de julio
de 2022

Tutores: Dr. José Francisco Díez Pastor y Dr.
Pedro Latorre Carmona

Universidades de Burgos, León y Valladolid



Máster universitario en Inteligencia de Negocio y Big Data en Entornos Seguros

D. José Francisco Díez Pastor, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos, y D. Pedro Latorre Carmona, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Exponen:

Que el alumno Ignacio Ponsoda Llorens, con DNI 21698927Z, ha realizado el Trabajo final de Máster en Inteligencia de Negocio y Big Data en Entornos Seguros titulado 'Clasificación de individuos a partir de imágenes oculares y redes neuronales pre-entrenadas'.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección de los que suscriben, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 11 de julio de 2022

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. José Francisco Díez Pastor

D. Pedro Latorre Carmona

Resumen

La utilización de la biometría para mejorar la seguridad, principalmente en lo referente al acceso de dispositivos electrónicos, es un recurso ampliamente empleado en la actualidad, siendo el iris uno de los elementos biométricos que mayores dificultades presentan para la suplantación de identidad.

La identificación de personas a través del iris se lleva a cabo extrayendo sus características más relevantes, comúnmente utilizando técnicas empíricas. No obstante, las redes neuronales han demostrado ser útiles para extraer las características del iris. Esta extracción se puede llevar a cabo no solo entrenando una red neuronal desde cero, sino también adaptando una ya pre-entrenada con imágenes donde el iris ha sido aislado.

Respecto a la segunda fórmula se plantean dos preguntas. En primer lugar, ¿Es necesario aislar el iris para llevar a cabo la adaptación de la red neuronal, o esta podría llevarse a cabo también de forma eficiente con las imágenes oculares completas? En segundo lugar, ¿una vez que se ha adaptado la red neuronal a el conjunto de datos, sería posible que esta llevase a cabo, no solo la extracción de características sino también la clasificación?

En este proyecto se han adaptado redes neuronales que inicialmente habían sido entrenadas en el reconocimiento de objetos, para que sean capaces de identificar a un individuo utilizando su imagen ocular.

Para ello, se han utilizado dos enfoques. En un primer enfoque, se han adaptado las redes neuronales con imágenes oculares completas. En el segundo enfoque, se han adaptado las redes neuronales utilizando imágenes exclusivamente de la zona del iris, la cual es a priori la zona de la imagen ocular que mejor permite la identificación de individuos.

Además, se han utilizado técnicas de aumento del número de muestras del conjunto de datos original, para así poder contar con un mayor número de muestras de cada individuo y también, mejorar la robustez de las redes neuronales adaptadas.

Los resultados muestran que las mejores tasas de clasificación se han dado en el enfoque donde se utilizaba la imagen ocular completa, sin que las técnicas de ampliación del conjunto de datos hayan permitido mejorar la tasa de clasificación.

II

Como futuras líneas de trabajo, se establecen dos. Por un lado, la adaptación de nuevas redes neuronales pre-entrenadas para comprobar cual se adapta mejor a esta metodología. Por otro lado, verificar los modelos resultantes con imágenes que hayan sufrido alteraciones, para comprobar su robustez.

Descriptores

biometría, iris, redes neuronales, imágenes oculares, *fine-tuning*, *data augmentation*, CASIA

Abstract

The use of biometrics to improve security, especially when it comes to access to electronic devices, it is a resource widely used today and, the iris is one of the biometric elements that present the greatest difficulties for identity fraud.

The identification of people through the iris is carried out by extracting their most relevant characteristics, commonly using empirical techniques. Nonetheless, neural networks have proven useful for extracting features from the iris. This extraction can be carried out not only by training a neural network from scratch but also by adapting an already pre-trained one with images where the iris has been isolated.

Regarding the second formula, two questions arise. First, is it necessary to isolate the iris to carry out the adaptation of the neural network, or could it also be carried out efficiently with full eye images? And secondly, once the neural network has been adapted to the dataset, would it be possible for it to perform not only feature extraction but also classification?

In this project, neural networks that had initially been trained in object recognition have been adapted so that they are capable of identifying an individual using their eye image.

To do this, two approaches have been used. In a first approach, neural networks have been adapted with whole eye images. In the second approach, the neural networks have been adapted using images exclusively of the iris area, which is a priori the area of the eye image that best allows the identification of individuals.

In addition, techniques have been used to increase the number of samples of the original data set, in order to have a greater number of samples from each individual and also improve the robustness of the adapted neural networks.

The results show that the best classification rates have been given in the approach where the complete ocular image was used, without the techniques of enlarging the data set having allowed improving the classification rate.

As future lines of work, two are established. On the one hand, the adaptation of new pre-trained neural networks to check which one best suits this methodology. On the other hand, verify the resulting models with images that have suffered alterations, to check their robustness.

Keywords

biometrics, iris, neural networks, fine-tuning, data augmentation

Índice general

Índice general	v
Índice de figuras	vii
Índice de tablas	viii
1. Introducción	3
1.1. Outline	8
Memoria	3
2. Objetivos del proyecto	9
3. Conceptos teóricos	11
3.1. Biometría	11
3.2. Inteligencia Artificial	13
4. Técnicas y herramientas	23
4.1. Hardware	23
4.2. Github	24
4.3. Python	24
4.4. SCRUM	25
5. Aspectos relevantes del desarrollo del proyecto	27
5.1. Preparación del conjunto de datos	28
5.2. Pre-procesamiento de los datos	28
5.3. Adaptación de la red neuronal	29

6. Trabajos relacionados	33
6.1. Sistema clasificador de iris	33
6.2. Iris Recognition Development Techniques: A Comprehensive Review	34
6.3. Deep Learning-Based Feature Extraction in Iris Recognition: Use Existing Models, Fine-tune or Train From Scratch?	35
7. Conclusiones y Líneas de trabajo futuras	37
7.1. Conclusiones	37
7.2. Líneas de trabajo futuras	37
Apéndices	39
Apéndice A Plan de Proyecto Software	41
A.1. Introducción	41
A.2. Planificación temporal	41
A.3. Estudio de viabilidad	43
Apéndice B Especificación de Requisitos	47
B.1. Introducción	47
B.2. Objetivos generales	47
B.3. Catalogo de requisitos	47
B.4. Especificación de requisitos	48
Apéndice C Especificación de diseño	51
C.1. Introducción	51
C.2. Diseño de datos	51
C.3. Diseño procedimental	52
C.4. Diseño arquitectónico	53
Apéndice D Documentación técnica de programación	55
D.1. Introducción	55
D.2. Estructura de directorios	55
D.3. Manual del programador	55
D.4. Compilación, instalación y ejecución del proyecto	61
D.5. Pruebas del sistema	62
Bibliografía	63

Índice de figuras

1.1. Segmentación de los bordes límbico y pupilar de forma clásica. . .	4
1.2. Ejemplo de imágenes completas e imágenes con el iris aislado. . .	5
1.3. Enfoque utilizando las imágenes sin preprocesamiento.	6
1.4. Enfoque utilizando la normalización y segmentación del iris. . .	7
3.5. Partes del ojo.	12
3.6. Representación del funcionamiento de una red neuronal, inspirada en el vídeo, <i>How Deep Neural Networks Work</i>	14
3.7. Ejemplo de <i>data augmentation</i> por ruido Gaussiano.	16
3.8. Ejemplo de transformación de identidad.	17
3.9. Ejemplo de transformación por reflexión.	17
3.10. Ejemplo de transformación por escalado.	18
3.11. Ejemplo de transformación por traslación.	18
3.12. Ejemplo de transformación por rotación.	19
3.13. Ejemplo de binarización del ojo durante la segmentación.	20
3.14. Ejemplo de normalización del ojo.	21
C.1. Estructura de directorios de CASIA-V1.	52

Índice de tablas

3.1. Transformaciones afines aplicadas en el trabajo.	16
4.2. Características del equipo	23
5.3. Conjuntos de datos utilizados para el <i>fine-tuning</i>	27
5.4. Configuración del <i>pipeline</i>	30
5.5. Tasa de acierto de los modelos.	32
A.1. Gastos de contratación del estudiante (en euros).	44
A.2. Gastos de contratación de los tutores (en euros por tutor).	44
A.3. Gastos totales del proyecto (en euros).	45
A.4. Licencias de las librerías utilizadas.	45

Memoria

Introducción

El *Oxford Learners Dictionaries* ¹ define la biometría como la utilización de características humanas para poder identificar a las personas. Esta idea se ha convertido en la base o principio fundamental de un número considerable de sistemas de seguridad.

Las principales características utilizadas para identificación de individuos son la cara, el iris, y las huellas dactilares. Estas características identificativas se han convertido en elementos de seguridad fundamentales para multitud de dispositivos.

Esta dependencia de la biometría para acceder a los dispositivos supone indirectamente una dependencia en ella para la protección de la información privada de la población, ya que hoy en día, los dispositivos electrónicos cuentan con gran cantidad de información sensible.

Dentro de la biometría, el iris se utiliza como un elemento de reconocimiento biométrico de gran eficacia, tanto por su inmutabilidad a lo largo del tiempo como por resultar un valor único y personal, que supone que dos personas no puedan ser identificadas con un mismo iris [9].

Para la utilización del iris como identificador a partir de una imagen ocular el procedimiento habitual es el siguiente. En primer lugar, se lleva a cabo una segmentación y una normalización del iris, para posteriormente extraer las características del iris, seleccionar las más significativas y, finalmente, llevar a cabo la clasificación [9].

Sin embargo, contar con técnicas eficientes de segmentación y extracción de atributos del iris hoy en día sigue siendo un problema. En muchos casos

¹Definición consultada en <https://www.oxfordlearnersdictionaries.com/definition/english/biometric>

se siguen utilizando técnicas clásicas que buscan encontrar bordes en el iris para poder aislarlo, como se muestra en la Figura 1.1, y ocurre algo similar con la extracción de características. No obstante, se ha demostrado que las redes neuronales pueden ser utilizadas para la segmentación del iris [8] y la extracción de características [2][3].

Existen dos opciones a la hora de trabajar con las redes neuronales para la extracción de características: (a) entrenar una red neuronal desde cero, (b) adaptar una ya existente al conjunto de datos a utilizar. Ha sido demostrado que el uso de redes neuronales adaptadas funciona mejor que las creadas desde cero cuando se aísla previamente el iris [3], pero surgen dos nuevas preguntas:

1. ¿Es necesario aislar el iris para llevar a cabo la adaptación de la red neuronal, o esta podría llevarse a cabo también de forma eficiente con las imágenes oculares completas?
2. ¿Una vez que se ha adaptado la red neuronal a el conjunto de datos, sería posible que esta llevase a cabo, no solo la extracción de características sino también la clasificación?




Figura 1.1: Segmentación de los bordes límbico y pupilar de forma clásica.

En este estudio, se ha adaptado una red neuronal pre-entrenada para la identificación de objetos para que sea capaz de identificar de individuos a través de sus imágenes oculares. Se proponen dos enfoques. Un primer enfoque donde la red neuronal se adapta con el conjunto de imágenes oculares completas y un segundo enfoque donde la red neuronal se adapta con el conjunto de imágenes, previo aislamiento del iris. Ejemplos imágenes

pertenecientes a cada conjunto de datos se pueden consultar en la Figura 1.2.




Figura 1.2: Ejemplo de imágenes completas e imágenes con el iris aislado.

En ambos enfoques se ha empleado la red neuronal VGG16², que ha sido pre-entrenada con ImageNet³. Esta red ha sido adaptada para clasificar individuos aplicando técnicas de *fine-tuning*⁴ con imágenes oculares etiquetadas. Estos dos enfoques han dado lugar a dos modelos de clasificación.

En un primer enfoque, se han utilizado las imágenes oculares completas del conjunto de datos⁵ para adaptar la red neuronal, siguiendo el proceso que se muestra en la Figura 1.3

²Esta red neuronal cuenta con 16 capas y ha sido entrenada con más de un millón de imágenes.

³ImageNet es un proyecto donde se proporciona una gran base de datos de imágenes para usos no comerciales <https://www.image-net.org/>

⁴El *fine-tuning* permite adaptar el modelo para que, al llevarse a cabo la clasificación, no muestre resultados relativos al conjunto de datos con el que ha sido entrenada, sino con el que ha sido adaptada, tal como se muestra en la Figura 1.3. El *fine-tuning* está definido en la sección 3.2.

⁵Revisar sección 3.1




Figura 1.3: Enfoque utilizando las imágenes sin preprocesamiento.

En un segundo enfoque, se ha aplicado un proceso de segmentación⁶ y normalización⁷ del iris, desarrollado en [2], al conjunto de imágenes, para aislar el iris en la imagen. Posteriormente, se ha seguido también un proceso de adaptación de la red neuronal. Este enfoque se muestra en la Figura 1.4.

⁶Definición de segmentación en la sección 3.2.

⁷Definición de normalización en la sección 3.2.




Figura 1.4: Enfoque utilizando la normalización y segmentación del iris.

Adicionalmente, y teniendo en cuenta que el conjunto de datos es relativamente pequeño (un total de siete imágenes oculares por individuo), se ha querido analizar el efecto de la utilización de un conjunto de datos de mayor tamaño para la adaptación de la red neuronal. Por ello, se han creado dos conjuntos de datos adicionales utilizando técnicas que aumenten artificialmente el número de imágenes por individuo.

Por ello, para ambos enfoques se han creado dos modelos adicionales aplicando técnicas de *data augmentation*⁸ para, por un lado, incrementar el número de imágenes oculares por individuo y, por otro, entrenar al modelo con nuevas variaciones de las imágenes, haciendo el modelo más robusto ante estas posibles nuevas variaciones.

El resultado de la adaptación de los cuatro conjuntos de imágenes a red neuronal ha sido la creación de cuatro modelos de clasificación, capaces de identificar a individuos a partir de una imagen ocular.

Para determinar qué enfoque ha sido capaz de identificar de forma más eficiente a los individuos, se ha comparado la tasa de acierto de los modelos resultantes de las adaptaciones a la hora de clasificar nuevas imágenes oculares.

El objetivo principal de este proyecto ha sido el de analizar cuál de estos enfoques es el óptimo para el reconocimiento de individuos a través de sus imágenes oculares, así como comprobar el efecto del *data augmentation* y el aislamiento del iris en las tasas de acierto.

⁸El término *data augmentation* hace referencia a un conjunto de técnicas que permite ampliar el conjunto de datos original con variaciones de el mismo. En la sección [Data augmentation](#) puede encontrar una explicación más detallada.

1.1. Outline

El resto del documento se estructura de la siguiente manera. El capítulo 2 [Objetivos del proyecto](#) define las principales motivaciones del proyecto. El capítulo 3 [Conceptos teóricos](#) se concentra en los aspectos teóricos del proyecto. En el capítulo 5 [Aspectos relevantes del desarrollo del proyecto](#) se muestran los aspectos más relevantes que se han desarrollado. En el capítulo 6 [Trabajos relacionados](#) los trabajos relacionados y en el capítulo 7 [Conclusiones y Líneas de trabajo futuras](#) las conclusiones y las líneas de trabajo futuras.

Objetivos del proyecto

En este apartado se detallan los objetivos principales para el desarrollo del proyecto:

- Adaptar el código de los procesos de segmentación y normalización utilizados en [2] mejorando su reproducibilidad y manejo.
- Aplicar técnicas que aumenten el tamaño del conjunto de datos y la robustez de los modelos entrenados con él.
- Crear un modelo completo de identificación de individuos adaptando una red neuronal pre-entrenada al conjunto de datos.
- Analizar la capacidad de identificación de los modelos desarrollados y el impacto que tienen el segundo y el tercer punto en las tasas de acierto de los modelos.

Conceptos teóricos

En esta sección se desarrollan los conceptos teóricos utilizados, y que son necesarios para comprender el proyecto.

3.1. Biometría

Tal como se ha descrito en el capítulo [Introducción](#), la biometría es el estudio que permite la identificación de un individuo a través de determinadas características asociadas a su persona, principalmente la cara, las huellas dactilares y el iris.

Partes del ojo

El ojo se divide en tres capas principales, la capa externa llamada esclerótica, la capa intermedia llamada iris y la capa interna llamada retina. Entre la capa externa e intermedia se encuentra el borde límbico, mientras que, en la capa intermedia, el borde pupilar separa el iris de la pupila⁹. Dichos bordes son cruciales a la hora de segmentar el iris, proceso que se describe en la sección [Segmentación](#). Las partes del ojo han sido etiquetadas en la Figura [3.5](#).

⁹Información accesible desde <https://www.cigna.com/es-us/individuals-families/health-wellness/hw/anatoma-y-funcin-del-ojo-hw121946>. 2022, 22 de junio




Figura 3.5: Partes del ojo.

Conjunto de datos CASIA-IrisV1

El conjunto de datos CASIA-IrisV1 ha sido el utilizado en el proyecto para adaptar las redes neuronales. Se trata de una base de datos que contiene 756 imágenes del iris de un total de 108 sujetos. Dichas fotos fueron tomadas por el *Center for Biometrics and Security Research* en dos sesiones, donde se tomaron 3 y 4 muestras respectivamente por cada individuo, con una resolución de 320×280 . La pupila fue automáticamente remplazada por la propia organización para evitar que en ella se reflejasen las luces de las fotografías¹⁰.

¹⁰El proceso de la toma de muestras se describe en <http://www.cbsr.ia.ac.cn/IrisDatabase.htm>.

3.2. Inteligencia Artificial

La Real Academia Española define la inteligencia artificial como una disciplina cuyo objetivo principal es la creación de programas capaces de realizar funciones similares a los de la mente humana¹¹. En este proyecto ha sido utilizada principalmente para la segmentación del iris, definida en la sección [Segmentación](#), y la adaptación de la red neuronal al conjunto de datos.

Deep Learning

El *deep learning* es un campo del *machine learning* y de la inteligencia artificial que imita el funcionamiento del cerebro humano y sus redes neuronales para adquirir conocimiento [6]. Para resolver los problemas que se le plantean, el *deep learning* intenta replicar la toma de decisiones que llevan a cabo los seres humanos a través de la experiencia y la jerarquización de conceptos.

Al basarse en la experiencia, el *deep learning* no necesita que se definan todos los parámetros para poder completar la tarea, puesto que es capaz de aprender por sí misma. Por otro lado, la jerarquización de conceptos permite utilizar conceptos complejos al basarlos en conceptos más fáciles de entender [6].

En el *deep learning*, la red neuronal cuenta con una capa de entrada y una capa de salida, y entre ellas cuenta con una o varias capas ocultas. Las capas están conectadas entre ellas por conexiones ponderadas, que determinan la importancia de cada elemento de la capa y que permite, en el caso de este proyecto, la identificación de individuos a través de su imagen ocular en la capa de salida. Este funcionamiento ha sido representado en la Figura 3.6.

¹¹En base a la definición de <https://dle.rae.es/inteligencia>.




Figura 3.6: Representación del funcionamiento de una red neuronal, inspirada en el vídeo [How Deep Neural Networks Work](#).

Pipeline

Los *pipelines* son secuencias de procesos encadenados, donde la salida del proceso anterior funciona como *input* del siguiente proceso.

Tomando como ejemplo la Figura 1.4, un primer proceso sería la segmentación, que tomaría como entrada el conjunto de datos de CASIA y tendría como salida las imágenes segmentadas. A su vez, estas imágenes segmentadas, serían la entrada del proceso de normalización, y así sucesivamente.

La utilización de *pipelines* en el proyecto ha permitido un mayor control de los distintos procesos, al poder establecer una configuración general en la cadena de procesos, y ha permitido modificar de forma más sencilla el orden

de estos procesos, permitiendo así experimentar con nuevas combinaciones de los procesos.

Data augmentation

La utilización de técnicas de *data augmentation* es un proceso común en el análisis de imágenes, y en general, en aquellos proyectos donde se utilicen procesos estadísticos.

El *data augmentation* consiste en incrementar el tamaño del conjunto de datos con la creación artificial de nuevas imágenes producidas a partir de imágenes del conjunto de datos original.

Para ello, la imagen original se modifica, comúnmente con la aplicación de ruido Gaussiano o transformaciones geométricas de tipo afín, obteniendo como resultado una imagen que deriva de la original, pero que cuenta con ciertas diferencias, más o menos pronunciada dependiendo de las técnicas de *data augmentation* que se le apliquen, así como de los parámetros utilizados para realizar las modificaciones¹².

En el caso de los procesos de entrenamiento de las redes neuronales, es común la utilización de técnicas de *data augmentation* principalmente por dos situaciones, aunque estas no son limitantes:

- **Número insuficiente de datos:** en este caso, el *data augmentation* se aplica porque el dataset no es lo suficientemente grande como para conseguir unos resultados significativos en la creación de una red neuronal.
- **Aumento de la robustez del modelo:** el segundo supuesto principal por el cual se utiliza *data augmentation* es la utilización de elementos que añadan complejidad a la creación del modelo, lo cual le proporcionará una mejor actuación ante la aparición de nuevas complejidades.

Ruido Gaussiano

La primera de las técnicas de *data augmentation* utilizadas es el ruido Gaussiano. También conocido como ruido blanco, esta técnica provoca que los píxeles de una imagen cambien su valor siguiendo una distribución gaussiana, como se puede observar en la Figura 3.7 .

¹²Por ejemplo, si se rota una imagen 2 grados, la diferencia con la original será mucho menor que si se rota 180 grados.




Figura 3.7: Ejemplo de *data augmentation* por ruido Gaussiano.

Transformaciones afines

Las transformaciones afines permiten aumentar el tamaño del dataset mediante la transformación de imágenes. Conservan el paralelismo de sus líneas rectas y paralelas y, de alguna forma, simulan una nueva perspectiva de la imagen original. Las transformaciones afines utilizadas en el proyecto han sido recogidas en la Tabla 3.1 y se describen a continuación.

Transformaciones afines				
Identidad	Reflexión	escalado	Traslación	Rotación
Figura 3.8	Figura 3.9	Figura 3.10	Figura 3.11	Figura 3.12

Tabla 3.1: Transformaciones afines aplicadas en el trabajo.

Identidad La transformación de identidad es un tipo de transformación afín en el que la imagen se copia sin ningún otro cambio, y se utiliza para la reutilización del conjunto de datos.




Figura 3.8: Ejemplo de transformación de identidad.

$$\text{Identidad} : \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \equiv \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3.1)$$

Reflexión Se trata de un mapeo aplicado a la imagen a partir de un eje.




Figura 3.9: Ejemplo de transformación por reflexión.

$$\text{Reflexión} : \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \equiv \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3.2)$$

escalado Esta transformación modifica la escala de la imagen original, ya sea ampliándola o disminuyéndola.




Figura 3.10: Ejemplo de transformación por escalado.

$$\text{escalado} : \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \equiv \begin{bmatrix} Sx & 0 & 0 \\ 0 & Sy & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3.3)$$

Traslación La imagen cambia de plano de coordenadas, pero no se modifican ni su tamaño, ni su forma, ni su orientación.




Figura 3.11: Ejemplo de transformación por traslación.

$$\text{Traducción} : \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \equiv \begin{bmatrix} 1 & 0 & dx \\ 0 & 1 & dy \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3.4)$$

Rotación Esta transformación aplica una transformación de θ grados del plano.




Figura 3.12: Ejemplo de transformación por rotación.

$$\text{Rotación} : \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \equiv \begin{bmatrix} \cos(\theta) & -\sin(\theta) & 0 \\ \sin(\theta) & \cos(\theta) & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (3.5)$$

Pre-procesamiento

El preprocesamiento es la manipulación de los datos para que se ha de llevar a cabo para que estos tengan el formato requerido por el procesamiento.

En el caso de este proyecto, la fase de pre-procesamiento se centra en el aislamiento del iris. Múltiples estudios [2] [1] [9] [4] [7] [10] [8] donde no se han aplicado redes neuronales para el proceso de clasificación, han demostrado que el aislamiento del iris en base primero a su segmentación y, posteriormente, a su normalización, han permitido una clasificación más eficiente de los individuos a partir de sus imágenes oculares, algo que reafirma el iris como la parte biométrica de la imagen.

Segmentación

En la fase de detección de los bordes *límpico* y *pupilar*¹³. La detección se ha llevado a cabo utilizando una red neuronal previamente entrenada para este fin [8]. Estos bordes son clave para el aislamiento del iris [2].

Una vez detectados los bordes, se procede a una binarización de la Figura 3.13, de forma que quede clara la división entre iris y resto del ojo.




Figura 3.13: Ejemplo de binarización del ojo durante la segmentación.

Normalización

La normalización del iris se puede definir como la proyección del iris segmentado a coordenadas polares (Figura 3.14), utilizando el método Daugman¹⁴ [5]. De esta manera, se igualan los tamaños de las diferentes imágenes y permiten su comparación.

¹³Definidos en la sección 3.1.

¹⁴Transforma el iris de coordenadas cartesianas a polares.




Figura 3.14: Ejemplo de normalización del ojo.

Fine-tuning

Se basa en adaptar redes neuronales, que previamente han sido entrenadas para reconocer ciertos objetos, con el fin de que pasen a reconocer los objetos de un nuevo conjunto de datos. Ello permite beneficiarse de las capacidades de la red neuronal a la hora de identificar objetos, teniendo que entrenar solamente las capas relacionadas con la identificación y el etiquetado final.

En el caso de este proyecto, el *fine-tuning* ha sido utilizado para obtener un clasificador de imágenes para el conjunto de datos de CASIA-Iris-V1 sin tener que crear una red neuronal desde cero, sino adaptando la red neuronal VGG16 para dicha función, algo que ha demostrado ser más eficiente [3].

Técnicas y herramientas

En esta sección se describen los instrumentos y recursos utilizados a lo largo del proyecto.

4.1. Hardware

Para la ejecución de los ficheros de Jupyter notebook, se ha contado con una máquina de la Universidad de Burgos, cuyas características se recogen en la Tabla 4.2.

Elemento	Característica
Procesador	Intel Xeon E5-2630 v4 @ 2.20GHz (4 núcleos)
Memoria	128GB
GPUs	3 x Titan XP
Discos	SSD 500Gb, 2 x HDD 2TB

Tabla 4.2: Características del equipo

Para interactuar con la máquina, se ha utilizado una conexión SSH ¹⁵ así como un cliente Putty ¹⁶, para la modificación de los *notebooks* a través de Jupyter *notebooks* ¹⁷, dentro del ecosistema de Anaconda ¹⁸.

¹⁵El *security shell* es un protocolo que permite el acceso remoto a través de un canal seguro <https://www.openssh.com/>.

¹⁶Putty es una implementación libre de SSH para Windows <https://www.putty.org/>.

¹⁷Se trata de una aplicación que permite editar y lanzar *notebooks* a través del buscador, <https://jupyter.org/>.

¹⁸Anaconda es una distribución libre, accesible a través del buscador, que es ampliamente utilizada en la ciencia de datos <https://www.anaconda.com/>.

4.2. Github

Github es una compañía que ofrece repositorios Git¹⁹ en la nube. Estos repositorios se han utilizado en el proyecto para:

1. Control de versiones.
2. Seguimiento de las fases del proyecto.
3. Documentación de las reuniones y de los problemas a resolver.

El repositorio del proyecto es accesible desde <https://github.com/Ponsoda/tfm-iris-recognition>.

4.3. Python

Se ha utilizado el lenguaje de programación [Python](#) para las distintas fases del proyecto.

Entre las principales librerías utilizadas se encuentran:

- [imageio](#) - leer y escribir imágenes.
- [keras](#) - manejo de las redes neuronales.
- [matplotlib](#) - visualización de datos e imágenes.
- [numpy](#) - trabajo con las imágenes a nivel de arrays.
- [os](#) - acceso a los directorios.
- [opencv](#) - trabajo con las imágenes.
- [scikit-image](#) - transformación de las imágenes y el uso de dataset.
- [shutil](#) - copia de directorios.
- [tensorflow](#) - modificación de las redes neuronales.

¹⁹Sistema de control de versiones <https://git-scm.com/>.

Redes neuronales

En el desarrollo del proyecto, se ha utilizado dos redes neuronales. En primer lugar, durante el proceso de adecuación del código procedente de [2], se ha utilizado una red neuronal basada en U-Net²⁰ y accesible desde el repositorio del *paper* [8]. Esta red neuronal, ya había sido específicamente entrenada para la segmentar el iris en imágenes oculares. Al tratarse de una red neuronal ya adaptada para dicho fin, se pudo utilizar directamente para la fase de extracción.

Para el proceso de *fine-tuning*, se ha utilizado la red neuronal VGG16, entrenada con el conjunto de datos de ImageNet para el reconocimiento de objetos, ya descrita en la sección de [Introducción](#).

Visual Studio Code

Tanto para la redacción de la memoria con LaTeX como para la creación de los *notebooks* a nivel local, se ha utilizado [Visual Studio Code](#).

Se trata de un IDE²¹ con licencia *open-source*, desarrollado por Microsoft que permite funciones de desarrollo, como la edición de código o su depuración.

4.4. SCRUM

SCRUM es un marco que ayuda a la organización de los equipos en torno a un proyecto, en base a *sprints* de una determinada duración y permite una retroalimentación continua del proyecto, de forma que se asegura que el equipo trabaje en consonancia.

En el caso de este proyecto, se ha adecuado la metodología de SCRUM para cuadrar reuniones semanales o quincenales con los tutores del proyecto, estableciendo los sprints y los objetivos de cada *sprint* utilizando la plataforma Github.

²⁰Red neuronal para la segmentación de imágenes biomédicas desarrollada por la Universidad de Freiburg <https://arxiv.org/abs/1505.04597>.

²¹Entorno de desarrollo integrado.

Aspectos relevantes del desarrollo del proyecto

El proyecto se ha dividido en dos fases principales. La primera fase ha consistido en la asimilación, adecuación y optimización del código perteneciente a [2] para utilizarlo posteriormente en las fases de pre-procesamiento. Es decir, en la de segmentación y la de normalización del iris. También se incluye en esta fase la aplicación de las técnicas de *data augmentation*. Por otro lado, en la segunda fase se ha desarrollado la adaptación de la red neuronal VGG16 a los conjuntos de imágenes derivadas del conjunto de datos creadas en la primera fase.

Los conjuntos de datos se utilizarán en la segunda fase, junto con el *fine-tuning* para crear los modelos finales. Con ellos, se calculará la tasa de acierto relativa a su capacidad de clasificación. Estos cuatro conjuntos de datos se reflejan en la Tabla 5.3.

Conjunto de datos	Pre-procesamiento	<i>Data augmentation</i>
1		
2	x	
3		x
4	x	x

Tabla 5.3: Conjuntos de datos utilizados para el *fine-tuning*.

5.1. Preparación del conjunto de datos

En los proyectos de inteligencia artificial, el procedimiento habitual para entrenar las redes neuronales es el de dividir los datos que se van a utilizar para entrenar a la red en dos subconjuntos. El subconjunto de mayor tamaño se utiliza para entrenar el modelo *per se*, mientras que el subconjunto de menor tamaño se utiliza en la validación de este.

En el caso de este proyecto caso, el conjunto de datos inicial ha sido dividido en un 70 % para la fase de entrenamiento, y un 30 % para calcular la tasa de acierto, siendo estos los porcentajes más comúnmente utilizados.

5.2. Pre-procesamiento de los datos

En la primera fase del proyecto, se ha llevado a cabo un pre-procesamiento del conjunto de datos para crear el conjunto de imágenes del iris aisladas.

Adecuación del código previo

Como se ha mencionado anteriormente, el código desarrollado en [2] para la segmentación y normalización del iris en una imagen ocular ha sido adaptado para este proyecto.

En primer lugar, se ha asimilado el trabajo completo, y en segundo lugar, se ha llevado a cabo la limpieza y adecuación del código para adaptarlo a las necesidades del proyecto.

El objetivo de este código es la creación de un segundo conjunto de imágenes donde se aísla el iris. Ello permite entrenar a la red neuronal únicamente con esta parte del ojo y evitar así el ruido que pueda causar el resto de la imagen.

Aplicación del *data augmentation*

El proceso de *data augmentation* permite ampliar el número de imágenes de un conjunto de datos y mejorar la robustez de los modelos de clasificación, al utilizar para su entrenamiento alteraciones en las imágenes. Dos conjuntos de datos adicionales han sido creados utilizando *data augmentation*.

Este proceso utiliza las técnicas de ruido Gaussiano y transformaciones afines, explicadas en la sección 3.2 para crear dos nuevos conjuntos de datos.

Para la aplicación del ruido Gaussiano, se han aplicado aleatoriamente valores de la desviación estándar de 2.5, 5 y 7.5.

Por su lado, las transformaciones afines se han aplicado de forma independiente al ruido Gaussiano, es decir, una no es excluyente de la otra, ni las transformaciones afines son excluyentes entre ellas mismas.

Como resultado del *data augmentation*, el conjunto de datos, que originalmente contaban con 756 imágenes, cuenta tras este proceso con 1158 imágenes.

Creación de la *pipeline*

Cada fase del proyecto ha sido definida en una sección del código.

Con el fin de mejorar el manejo de las diferentes secciones, se ha optado por la utilización de una pipeline que permitiese controlar fácilmente la secuencia de ejecución del código así como la configuración del mismo.

Para ello, se ha encapsulado cada uno de los procesos del proyecto en funciones independientes y se ha creado un diccionario donde se ha establecido la configuración inicial.

Este diccionario es el único elemento de entrada y salida en la pipeline y permite que en cada proceso se pueda modificar o ampliar el diccionario, haciendo posible el cambio del orden de los procesos en el pipeline.

Los criterios de la configuración de la pipeline se muestran en la siguiente Tabla 5.4. El *pipeline* se explica más detalladamente en el Anexo D.3.

5.3. Adaptación de la red neuronal

La adaptación de la red neuronal VGG16²² es una parte central en el proyecto. Esta se ha aplicado a los cuatro conjuntos de datos desarrollados. Por un lado, a los dos conjuntos de datos sin pre-procesamiento (uno de ellos con *data augmentation*) y, por otro lado, a los dos conjuntos de datos a los que se les ha aplicado el pre-procesamiento (de nuevo, a uno de ellos se le han aplicado técnicas de *data augmentation*).

²²Se ha elegido esta red neuronal puesto que en [2] era la que mejores resultados de clasificación devolvía de forma promedio.

Nombre	Configuración
Raíz	Establecimiento del directorio raíz
Tamaño dataset	Tamaño de los conjuntos de datos de entrenamiento y validación
<i>Data augmentation</i>	Tipo de <i>data augmentation</i> a aplicar
Imágenes y gráficas	Mostrar imágenes y gráficas, configurado individualmente para cada elemento.
Modelo	Nombre y ubicación donde guardar la red neuronal.
Epochs	Número de epochs por cada red neuronal entrenada.
<i>Batch</i>	Tamaño del <i>batch</i> .
<i>Random seed</i>	Tamaño del <i>random seed</i> .
Peso	Peso utilizado para el entrenamiento la red neuronal.
<i>Fine-tuning</i>	conjunto de datos ha utilizar para el <i>fine-tuning</i> .

Tabla 5.4: Configuración del *pipeline*

Aplicación del *fine-tuning*

La utilización de técnicas de *fine-tuning* para la adaptación de la red neuronal VGG16 a los conjuntos de datos del proyecto se ha llevado a cabo en tres fases.

Primera fase

En una primera fase, se ha definido una primera red neuronal cuyo objetivo ha sido el de determinar las características que mejor definen a las imágenes, siendo esta red la que funcionará como la base del nuevo modelo.

Para definir esta red neuronal, se ha eliminado la capa final, que corresponde a la clasificación de la imagen. El modelo se establece en este punto como no entrenable para que no se re-entrene en la siguiente fase, de forma que el modelo resultante funcione como un *inference model*²³.

²³Este modelo aprovecha el conocimiento de una red neuronal ya entrenada para clasificar imágenes pero interfiere en el resultado final, que es modificado por un nuevo conjunto de datos, que suele ser de un tamaño no lo suficientemente grande para entrenar la red neuronal desde cero.

Segunda fase

En la segunda fase, se ha creado una nueva capa a partir del modelo base, que es capaz de clasificar a las imágenes a partir de las imágenes oculares y sus etiquetas.

Tercera fase

En esta tercera fase, se pasa a entrenar el modelo completo, descongelando el modelo base, pero manteniéndolo como *inference model* para evitar que se vuelva a entrenar, por lo que la extracción de características y la clasificación se hará en base al nuevo conjunto de datos, pero las capas intermedias utilizadas serán principalmente las de la red neuronal VGG16.

Clasificación de imágenes

Las imágenes se han clasificado utilizando los cuatro modelos creados en la sección 5.3. Para ello, se utiliza como conjunto de datos de entrada para el modelo, el 30 % reservado en la Sección 5.1.

Estos modelos reciben una imagen y determinan el porcentaje de que dicha imagen pertenezca a cada una de las clases posibles, que son las clases con las que se ha entrenado el modelo. En este caso, cada clase representa a un individuo. Para calcular la tasa de acierto, se ha tenido que ir más allá de los porcentajes y determinar que clase se asigna a cada imagen. Se ha determinado que la clase con un porcentaje más alto será la clase asignada a la imagen.

En el caso las imágenes normalizadas, antes de ser clasificadas, se les aplica la fase de pre-procesamiento, descrita en la Sección 3.2, de forma que estas se ajusten a la entrada requerida por el modelo.

Tasa de acierto

La tasa de acierto representa el número de veces que el modelo a determinado correctamente la clase de la imagen. O lo que es lo mismo, a que individuo pertenece cada imagen ocular.

En la Tabla 5.5, se puede observar la tasa de acierto que han tenido los modelos, a la hora de relacionar las imágenes con los individuos. El cálculo de este valor se explica detalladamente en el Anexo D.3.

Estos resultados muestran, en primer lugar, que el *data augmentation* no supone sino un decremento en la tasa de acierto, tanto en los casos

	Sin pre-procesamiento		Con pre-procesamiento	
Modelo	Sin <i>data augmentation</i>	Con <i>data augmentation</i>	Sin <i>data augmentation</i>	Con <i>data augmentation</i>
Acierto	0.94	0.93	0.72	0.68

Tabla 5.5: Tasa de acierto de los modelos.

donde se ha aislado el iris como en los que no. Esto puede deberse a que, aunque el modelo si tenga una mayor robustez frente a imágenes alteradas, el conjunto de datos de verificación no ha sufrido ninguna modificación. Por lo tanto, la mejora de la clasificación frente a imágenes con alteraciones, que se le presupone al *data augmentation*, no ha podido ser comprobada. No obstante, la mejora de la robustez previsiblemente permitirá al sistema funcionar de forma más eficiente en un contexto no controlado, donde las imágenes puedan sufrir alteraciones.

Por otro lado, en cuanto a los mejores resultados utilizando imágenes no pre-procesadas, se debe de tener en cuenta la forma en la que funcionan las redes neuronales. Estas reducen las imágenes para quedarse con sus características más representativas. Existe la posibilidad de que, al proporcionar más elementos representativos del individuo en la imagen, y no solo el iris, la propia red neuronal haya sido capaz de encontrar características en la imagen que son más eficientes para su clasificación, y que, de alguna forma, son ajenos a la zona propiamente del iris.

Además, cabe de tener en cuenta que, tal como se explica en la Sección 3.1, el conjunto de datos utilizado ha sido sometido a un preprocesamiento previo, en el que se manipuló la pupila para eliminar el brillo emitido por las cámaras al tomar las propias imágenes. Por lo tanto, realmente el pre-procesamiento practicado solo ha tenido efecto sobre la parte exterior al iris, y esto puede haber reducido su efecto.

Trabajos relacionados

La utilización del iris como elemento biométrico para el reconocimiento de personas ha sido un tema de estudio recurrente en las últimas dos décadas. Además, recientemente han visto la luz estudios que utilizan las redes neuronales para la segmentación y la extracción de características del iris.

A continuación, se describen algunos de los trabajos centrados en la identificación de individuos a través de su iris en los que se ha basado este proyecto.

6.1. Sistema clasificador de iris

En este trabajo final de grado [2] de la Universidad de Burgos, se desarrolla un sistema de clasificación de individuos basado en el iris. Para llevar a cabo la clasificación, se utiliza el conjunto de datos de CASIA-V1. Este se somete primero a segmentación, utilizando la red neuronal desarrollada en [8], y luego a normalización con el método Daugman.

Posteriormente, se extraen los atributos más identificativos de cada iris utilizando distintas redes neuronales pre-entrenadas y finalmente, se procede a la clasificación de individuos utilizando técnicas de *machine learning*.

Como se ha comentado anteriormente, el código para la carga de imágenes y los procesos de segmentación y normalización del iris, desarrollados en este proyecto, han sido utilizados de este trabajo como base de las mismas secciones en el *pipeline*. El *pipeline* se explica más detalladamente en el Anexo D.3.

6.2. Iris Recognition Development Techniques: A Comprehensive Review

En este artículo [9] de un grupo de investigadores de la Universiti Putra Malaysia, se habla de siete pasos en los que se divide un sistema de reconocimiento del iris:

1. adquisición
2. preprocesamiento
3. segmentación
4. normalización
5. extracción de características
6. selección de rasgos únicos y característicos
7. clasificación.

Este *paper* también describe una falta de trabajos entorno a *datasets* de baja calidad y realza que los sistemas de reconocimiento del iris se vuelven poco efectivos cuando las imágenes tienen rotaciones or reflejos, algo que ha sido aplicado a este proyecto, con el *data augmentation* (sección 3.2).

El mismo artículo se resumen los distintos conjunto de datos utilizados para los estudios de reconocimiento de iris en los últimos años, el tipo de ruido utilizado en cada uno de ellos, así como a grandes rasgos, cual es el método seguido en ellos para realizar el reconocimiento de individuos a través de sus imágenes oculares.

Gracias a este artículo, se puede determinar que comúnmente, para los pasos mencionados anteriormente, se utiliza por lo general tipos de segmentación tradicional, basado en la creación de círculos estandarizados, aunque aparece un incremento del uso de las redes neuronales para la segmentación en los últimos años. También se describen distintas técnicas de normalización del iris y extracción de sus características, así como distintos enfoques en el cálculo de la tasa de acierto en las clasificaciones.

6.3. Deep Learning-Based Feature Extraction in Iris Recognition: Use Existing Models, Fine-tune or Train From Scratch?

En este artículo [3], los investigadores de la Universidad de Notre Dame se preguntan si vale la pena, teniendo un conjunto de imágenes oculares de un tamaño considerable, entrenar a una red neuronal desde cero o aplicar técnicas de *fine-tuning* sobre una red ya pre-entrenada.

Para contestar a esta pregunta, utilizan técnicas de *deep learning* para clasificar imágenes de ojos del conjunto de datos CASIA 10k sin aplicar técnicas de *data augmentation* sobre él. Para la segmentación y normalización del iris se utilizan OSIRIS²⁴.

Para la parte de *fine-tuning*, se utiliza la red pre-entrenada ResNet50 y posteriormente, se realiza la clasificación con SVM²⁵. La conclusión que se extrae del artículo es que, al menos en este caso, el clasificador funciona mejor al adaptar una red neuronal con *fine-tuning* antes que crear la nuestra propia, aun siendo el conjunto de datos lo suficientemente grande para hacerlo.

²⁴Herramienta de código abierto utilizada para el reconocimiento del iris <https://github.com/tohki/iris-osiris>.

²⁵Support vector machine es un método de aprendizaje supervisado.

Conclusiones y Líneas de trabajo futuras

En este apartado se explican las conclusiones del proyecto, así como se establecen las posibles líneas de trabajo futuras.

7.1. Conclusiones

Como conclusión de este proyecto, se puede determinar que la utilización de técnicas de *fine-tuning* para llevar a cabo todo el proceso de clasificación, resultan, en este caso de estudio, más eficientes cuanto se utiliza la imagen ocular completa, y no cuando se aísla la zona del iris, como se podía pensar al entender que el iris es, con diferencia, la parte más característica del ojo.

Por otro lado, la utilización de técnicas de *data augmentation* con el fin de aumentar el tamaño de los conjuntos de datos y permitir la creación de unos modelos más robustos, no a influido positivamente en las tasas de acierto de los modelos, sino todo lo contrario.

7.2. Líneas de trabajo futuras

Las líneas de trabajo futuras se podrían determinar con la utilización de estas técnicas con distintos conjuntos de datos, utilizando imágenes que no estén específicamente preparadas para este tipo de estudios. Además, sería interesante probar distintos modelos para el *fine-tuning* de los distintos conjuntos de datos así como la utilización de redes neuronales para llevar a cabo el proceso de segmentación del iris.

El objetivo de todo ellos sería el conseguir un modelo lo suficientemente robusto que permitiese su utilización en un programa de escritorio, con una primera fase de *fine-tuning* con imágenes del ojo del usuario y una segunda fase donde este se utilizase como método de seguridad para el acceso a ciertos documentos de los dispositivos electrónicos.

Apéndice

Apéndice A

Plan de Proyecto Software

A.1. Introducción

La planificación del proyecto ha sido una parte esencial del proyecto, puesto que ha permitido la coordinación entre estudiante y tutores de forma online.

A.2. Planificación temporal

Para la planificación temporal se ha utilizado la metodología SCRUM basada en *sprints*, generalmente de una o dos semanas.

Sprint 1 (22/09/2021 - 15/09/2021)

- Creación de un repositorio para el control de las versiones y el seguimiento del trabajo.
- Investigación sobre la materia de estudio (antecedentes, casos de uso, estado del arte)
- Investigación sobre posibles dataset de iris para el estudio.
- Investigación sobre la metodología que mejor se adapte al proyecto.
- Estudio sobre el uso de *data augmentation* sobre *datasets* de iris.
- Investigación sobre el uso de pipelines para la mejora de la reproducibilidad del trabajo.

- Investigación sobre los transformes de scikit-learn

Sprint 2 (15/09/2021 - 06/10/2021)

- Investigación sobre *pipelines* que se ejecuten de forma condicional.
- Investigación sobre posibles redes neuronales para la segmentación del iris.
- Investigación para el uso de *data augmentation* en el paquete Keras.

Sprint 3 (06/10/2021 - 20/10/2021)

- Clarificación de objetivos del proyecto.
- Pruebas con la utilización de ruido Gaussiano con *standard deviation* aleatorio
- Investigación sobre las transformaciones afines como método para el *data augmentation*.
- Implementación del pipeline.

Sprint 4 (20/10/2021 - 03/11/2021)

- Pruebas con las transformaciones afines de Keras.

Sprint 5 (03/11/2021 - 11/11/2021)

- Pruebas con el transformador de Keras.

Sprint 6 y 7 (11/11/2021 - 09/12/2021)

- Aplicación de *fine tunning* con redes neuronales.

Sprint 8 (09/12/2021 - 28/12/2021)

- Reconfigurar el pipeline para que el *data augmentation* solo se aplique al conjunto de entrenamiento.

- Prevención de imágenes no segmentadas correctamente para prevenir que entren en el proceso de normalización.
- Incorporación del modelo de *deep learning* al *pipeline*.
- Mejora de la configuración del *pipeline*.

Sprint 9 (28/12/2021 - 10/03/2022)

- Creación de los modelos de clasificación.

A.3. Estudio de viabilidad

En este apartado se redacta la viabilidad del proyecto, tanto económica como legal, que potencialmente habría afrontado el proyecto.

Viabilidad económica

En primer lugar, se encuentran los cálculos económicos del proyecto, que se pueden dividir en gastos de *software*, *hardware* y de personal.

Software

Los recursos utilizados para la realización gratuitos y de código abierto, por lo que no se prevé ningún gasto en este apartado.

Hardware

Para la realización del proyecto, se ha contado con una máquina de la Universidad de Burgos, cuyas características se reflejan en la Tabla 4.2. En base a las características, el precio para esta máquina se establece entre los 2.500 y los 3.000 euros.

Teniendo en cuenta que la máquina tiene un periodo de amortización de 5 años, al haber sido utilizada durante 6 meses, el coste ascendería a 300 euros.

Personal

Finalmente, se ha de tener en cuenta que el proyecto se ha llevado a cabo por el estudiante y dos tutores.

Considerando que el proyecto se ha llevado a cabo en aproximadamente en 6 meses, se considerará que el estudiante trabajaría a tiempo completo durante ese tiempo, con un sueldo de 1500 euros al mes, cuyo gasto total para la universidad sería de unos 2400 euros al mes. Véase Tabla A.1

Gasto	Cantidad en euros
Base de cotización	1500
Coste seguridad social empresa	898
Total universidad	2398

Tabla A.1: Gastos de contratación del estudiante (en euros).

Por su parte, la tutorización del proyecto supone 0.5 créditos para el profesor. Suponiendo que el salario medio del tutor es de 43.400 euros brutos, la tutorización supondrá 900 euros (1800 al tratarse de dos tutores). Véase Tabla A.2.

Gasto	Cantidad en euros
Base de cotización	900
Coste seguridad social empresa	476
Total universidad	1376

Tabla A.2: Gastos de contratación de los tutores (en euros por tutor).

Gasto total

Por lo tanto, el gasto total se establece en, como se desglosa en la siguiente Tabla A.3.

Viabilidad legal

Como se ha comentado anteriormente, el *software* utilizado es gratuito y libre, y está sujeto a las licencias recogidas en la Tabla A.4.

El conjunto de datos utilizado tiene fines de investigación, pero no se permite la distribución alterada ni la misma y su uso no referenciado.

Gasto	Cantidad en euros
<i>Hardware</i>	300
Contratación estudiante	14400
Contratación tutores	2752
Total	17452

Tabla A.3: Gastos totales del proyecto (en euros).

Librería	Versión	Licencia
Anaconda	2.1.1	Libre
Imageio	2.19.3	BSD
Jupyter Notebook	4.11	BSD
Keras	2.7	MIT
Matplotlib	3.1	BSD
Numpy	1.19.5	BSD
OpenCV	4.6	BSD
Pandas	1.4.3	BSD
Python	3.10.5	PFS
Scikit-Learn	1.0	BSD
TensorFlow	2.9.1	Apache

Tabla A.4: Licencias de las librerías utilizadas.

Finalmente, se han utilizado los iconos de <https://www.flaticon.com/> para la elaboración de las gráficas. La licencia de los mismos no permite comercializarlos o modificarlos.

Apéndice *B*

Especificación de Requisitos

B.1. Introducción

En este apartado se especifican los objetivos generales del proyecto, así como cuales son los requisitos para su consecución.

B.2. Objetivos generales

Los objetivos generales son, el ser capaz de asimilar el trabajo de [2], modificar el código para hacerlo reutilizable y, finalmente, ser capaz de utilizar técnicas de *fine-tuning* con el conjunto de imágenes sobre una red neuronal ya pre-entrenada.

B.3. Catalogo de requisitos

Los requisitos del proyecto son los siguientes.

1. Optimizar del código previo.
2. Crear los modelos para la clasificación de imágenes oculares.
 - a) Dividir el conjunto de datos en entrenamiento y test.
 - b) Aplicar de *data augmentation*.
 - c) Segmentar de las imágenes.
 - d) Normalizar de las imágenes.

3. Aplicar *fine-tuning* a los distintos *datasets*.
4. Crear una configuración donde el usuario pueda modificar los parámetros y visualizar los distintos *outputs*.
5. Determinar qué proceso de *fine-tuning* proporciona una tasa de acierto más alta.

B.4. Especificación de requisitos

Optimizar el código previo

Asimilar y optimizar el código previo para que sea funcional. Para llevar a cabo este apartado es necesario contar con el código y el conjunto de datos, ambos accesibles desde https://github.com/jaa0124/iris_classifier/.

Crear los modelos para la clasificación de imágenes oculares

La clasificación de las imágenes oculares se lleva a cabo utilizando modelos adaptados utilizando distintos *datasets*. Su creación se lleva a cabo en las siguientes fases:

Dividir el conjunto de datos en entrenamiento y test

División del conjunto de datos de CASIA en entrenamiento y test, para poder validar los modelos. Los requisitos previos son el 1.

Aplicar de *data augmentation*

Aplicación de *data augmentation* sobre dos de los modelos. Los requisitos previos son el 1 y el 2a. Este paso solo se aplica a dos de los *datasets*.

Segmentar de las imágenes

Segmentación de las imágenes donde el iris será aislado. Los requisitos previos son 1, 2a y 2b. Este paso solo se aplica a dos de los *datasets*.

Normalizar de las imágenes

Normalización de las imágenes donde el iris será aislado. Los requisitos previos son 1, 2a, 2b y 2c. Este paso solo se aplica a dos de los *datasets*.

Aplicar *fine-tuning* a los distintos *datasets*

Aplicación de *fine-tuning* sobre los datasets. Los requisitos previos son Los requisitos previos son 1, 2a, 2b, 2c y 2d. Dependiendo del conjunto de datos, alguno de los pasos previos puede no ser necesario.

Crear una configuración donde el usuario pueda modificar los parámetros y visualizar los distintos *outputs*

Creación de una *pipeline* y establecimiento de su configuración para permitir al usuario adaptar el código a sus necesidades. Todos los pasos anteriores son requisitos previos.

Determinar qué proceso de *fine-tuning* proporciona una tasa de acierto más alta

Determinación de los valores más altos de la tasa de acierto en los distintos modelos.

Apéndice C

Especificación de diseño

C.1. Introducción

A continuación, se presentan las características asociadas al diseño del proyecto, con el fin de entender mejor como se han construido las distintas partes del proyecto.

C.2. Diseño de datos

conjunto de datos

Tal como se ha explicado en la memoria, se ha utilizado el conjunto de datos CASIA-V1.

La estructura de datos es la siguiente, por persona y sesión. Figura [C.1](#).

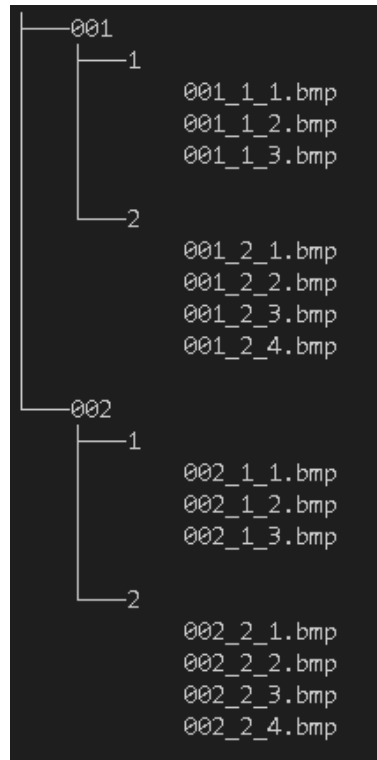


Figura C.1: Estructura de directorios de CASIA-V1.

Jupyter *Notebook*

El código del proyecto se ha reducido a dos documentos de Jupyter *notebook*:

- El primero es el `pipeline.ipynb`, en el cual se ha reducido todas las secciones del proyecto, encapsuladas en una *pipeline*.
- El segundo es el `accuracy.ipynb`, donde se lleva a cabo el cálculo de la tasa de acierto de los modelos.

C.3. Diseño procedimental

1. Carga de datos
2. *Data augmentation*
3. Segmentación y clasificación

4. *Fine-tuning*

5. Tasa de acierto

C.4. Diseño arquitectónico

Con la utilización de un *pipeline* configurable, se ha pretendido que el código utilizado en este proyecto pueda ser re-utilizado y permita modificar su configuración de una manera más sencilla.

Apéndice D

Documentación técnica de programación

D.1. Introducción

En este apartado se determinará la forma de proceder para poder replicar el proyecto por parte de programadores. En el se explica la estructura de los directorios así como la función de las distintas partes del código.

D.2. Estructura de directorios

- 06_Models contiene los modelos finales
- img contiene las imágenes utilizadas en el propio repositorio
- memoria, incluye la memoria
 - tex, contiene los archivos tex
 - img, contiene las imágenes del proyecto
- src, incluye el código del proyecto con distintas versiones

D.3. Manual del programador

Los *notebooks* del proyecto se pueden explorar en cualquier plataforma compatible con Jupyter notebooks.

Notebook pipeline.ipynb

El *notebook pipeline.ipynb* contiene el código principal del proyecto. A continuación se detallan sus partes.

Configuración

La configuración del *pipeline* se muestra a continuación. En ella, se establece primero una configuración general, es decir, que es aplicable a las distintas secciones. En ella se han configurado las rutas en las que se guardan los distintos *datasets*. Si todo el código es ejecutado, solo el '*root-dir*' se mantendrá, y el resto se irán sobrescribiendo cuando se cree el propio conjunto de datos. No obstante, la capacidad de establecer todas las rutas en la configuración es lo que nos permite cambiar el orden de las secciones en el *pipeline*.

- *tratarDataset*
 - *general_train_size*, tamaño del conjunto de datos que será utilizado para el entrenamiento [Valor del 0-1].
 - *show_first*, mostrar primera imagen [boolean].
- *dataAugmentation*
 - *gaussianNoise*, aplicación del ruido Gaussiano [boolean].
 - *stdGN*, valores de ruido Gaussiano a aplicar en las imágenes [valores menores de 10].
 - *afinTransformation*, aplicación de transformaciones afines [boolean].
- *segmentation*
 - *redNeuronal*, nombre de la red neuronal a utilizar [extensión .h5].
 - *verImagenV1*, ver la imagen producida [boolean].
- *CNN_classification*
 - *dataset_dir*, directorio a utilizar ['raw', para la imagen ocular completa o 'normalizado', para la imagen del iris aislada].
 - *verImagenV1*, ver la imagen producida [boolean].
 - *CNN_weights*, establecer de donde utilizar los pesos para la red neuronal [imagenet, None, o se le pasa un directorio con los pesos].

- *train_size*, tamaño del conjunto de datos de entrenamiento [0-1].
- *test_size*, tamaño del conjunto de datos de testeo [0-1].
- *batch_size*, tamaño del *batch* [debe de ser menor del tamaño del conjunto de datos].
- *epochs1*, establecer el tamaño del *epochs* para entrenar al primer modelo [10-100].
- *plt_accuracy1*, mostrar gráfica con el *accuracy* del primer modelo [boolean].
- *epochs2*, establecer el tamaño del *epochs* para entrenar al segundo modelo [8-80].
- *plt_accuracy2*, mostrar gráfica con el *accuracy* del segundo modelo [boolean].
- *epochs3*, establecer el tamaño del *epochs* para entrenar al tercer modelo [8-50].
- *plt_accuracy3*, mostrar gráfica con el *accuracy* del tercer modelo [boolean].
- *results_array*, mostrar el *array* de resultados [boolean].
- *save_model*, guardar el modelo [boolean].
- *save_model_name*, nombre con el que guardar el modelo [texto].

```

confi_dict = {

    'general':{
        'root_dir':r"/home/root_folder",
        'dataset_dir': "CASIA-IrisV1",
        'dataset_unif_dir': r"./CASIA-IrisV1_unif",
        'dataset_unif_dir_aug':r"./CASIA-IrisV1_unif_aug",
        'dataset_unif_segv2_edg_norm_dir' : r"./CASIA-
            ↪ IrisV1_unif_segv2_edg_norm",
        'dataset_unif_dir':r"./CASIA-IrisV1_unif_aug",
        'dataset_unif_segv2_edg_norm_dir' : r"./CASIA-
            ↪ IrisV1_unif_aug_segv2_edg_norm",
        'dataset_unif_dir': r"./CASIA-IrisV1_reservado"
    },

    '1_tratarDataset':{

```

```

        'general_train_size': 0.7,
        'show_first' : False
    },

    '1.1_dataAugmentation':{
        'gaussianNoise' : True,
        'stdGN': [2.5, 5, 7.5],
        'afinTransformation': True
    },

    '2.1_segmentation':{
        'redNeuronal' : "Iris_unet_d5.h5",
        'verImagenV1' : False
    },

    # Dataset dir can be "normalizado" or "raw"

    '4_CNN_classification' :{
        'dataset_dir' : "normalizado",
        'CNN_weights' : "imagenet",
        'train_size' : 0.7,
        'test_size' : 0.3,
        'batch_size' : 10,
        'epochs1' : 50,
        'plt_accuracy1' : True,
        'epochs2' : 40,
        'plt_accuracy2' : True,
        'epochs3' : 25,
        'plt_accuracy3' : True,
        'results_array' : True,
        'save_model' : False,
        'save_model_name' : "models/normalizado_aug_modelv1"
    }
}

```

Secciones

Las secciones con las que cuenta el *pipeline* son las siguientes:

1. *tratar_dataset_casia*

- Modificación de la configuración de archivos vista en el Anexo [C.2](#) a una configuración de directorio único.

2. *data_augmentation*

- Aplicación de transformaciones afines.
- Aplicación del ruido Gaussiano.

3. *segmentation*

- Genera las muestras que se le pasaran a la red pre-entrenada.
- Segmenta el iris.

4. *normalization*

- Establece los círculos correspondientes a los bordes del ojo.
- Binarización de las imágenes.
- Proyección de la sección del iris.

5. *extraction* (parte del código adaptado, no utilizado en este proyecto).6. *clasification* (parte del código adaptado, no utilizado en este proyecto).7. *clasificacionCNN*

- Adaptación del conjunto de datos al modelo de entrada de la red neuronal.
- División del conjunto de datos para el entrenamiento y el testeo.
- Construcción de los tres modelos.
- Muestra de resultados y de un ejemplo de clasificación.

Ejecución del *pipeline*

Cada una de las secciones anteriores ha sido encapsulada en una única función, con la configuración del *pipeline* como único parámetro de entrada. Para ejecutar el *pipeline* se establece cada función dentro de un *FunctionTransformer* y se coloca en el orden requerido dentro de la función *Pipeline*. Finalmente, se ejecuta el *pipeline*, pasándole la configuración como parámetro.

```

_1_tratar_dataset_pip = FunctionTransformer(
    ↪ tratar_dataset_casia)
_1_1_data_augmentation_pip = FunctionTransformer(
    ↪ data_augmentation)
_2_1_segmentation_pip = FunctionTransformer(segmentation)
_2_2_normalization_pip = FunctionTransformer(normalization)
_4_clasificacionCNN_pip = FunctionTransformer(clasificacionCNN
    ↪ )

iris_recognition_pipeline = Pipeline([('_1_tratarDataset',
    ↪ _1_tratar_dataset_pip),
    ('_1_1_dataAugmentation', _1_1_data_augmentation_pip),
    ('_2_1_segmentation', _2_1_segmentation_pip),
    ('_2_2_normalization', _2_2_normalization_pip),
    ('_3_1_extraction', _3_1_extraction_pip),
    ('_3_2_clasificacion', _3_2_clasificacion_pip),
    ('_4_clasificacionCNN', _4_clasificacionCNN_pip) ])

iris_recognition_pipeline.transform(confi_dict)

```

Notebook accuracy.ipynb

El *notebook accuracy.ipynb* permite el cálculo de la tasa de acierto de los modelos, utilizando los modelos creados en el apartado anterior, así como el conjunto de datos reservado para realizar el testeo.

Código

El código del *notebook* está dispuesto de la siguiente forma:

- *model*, ruta del modelo a utilizar.
- *test_path_dir*, ruta del conjunto de datos de testeo.
- *size* y *__parse_image*, configuración para adaptar la imagen al formato requerido por el modelo.
- *realClass_array*, *array* con la clase real de las imágenes.
- *predicted_array*, *array* con la clase predicha de las imágenes.

- *m.update_state*, obtiene las dos *arrays* anteriores de entrada y determina la tasa de acierto del modelo.

```

model = keras.models.load_model(r"root_folder/models/
    ↪ normalizado_aug_modelv1")
test_path_dir = r'root_folder/CASIA-
    ↪ IrisV1_unif_aug_segv2_edg_norm'
size = (224, 224)

def _parse_image(filename):
    img = tf.io.read_file(filename)
    img = tf.image.decode_bmp(img, channels = 3)
    img = tf.image.resize(img, size)
    img = tf.expand_dims(img, 0)
    return img

paths_array = np.array([x.__str__() for x in pathlib.Path(
    ↪ test_path_dir).rglob('*.bmp')])
realClass_array = np.array([x.split("/")[-1].split("_")[0] for
    ↪ x in paths_array]).astype(int)
predicted_array = np.array([])
for i in paths_array:
    result = model.predict(_parse_image(i))
    predicted_array = np.append(predicted_array, np.argmax(
        ↪ result) + 1)

m = tf.keras.metrics.Accuracy()
m.update_state(realClass_array, predicted_array)
m.result().numpy()

```

D.4. Compilación, instalación y ejecución del proyecto

Pasos para la ejecución del proyecto:

- Clonar el repositorio del proyecto <https://github.com/Ponsoda/tfm-iris-recognition>.

- Descargar el conjunto de datos de CASIA-V1. En el proyecto se ha utilizado el conjunto de datos a partir de https://github.com/jaa0124/iris_classifier/tree/master/notebooks/CASIA-IrisV1.
- Abrir el *notebook* `pipelines.ipynb`.
- Determinar la ubicación del conjunto de datos de CASIA-V1 en la configuración del *pipeline*, así como el resto de parámetros y el directorio de salida para los modelos.
- Ejecutar todas las celdas del proyecto en el orden definido en el proyecto para la creación de cada uno de los modelos.
- Abrir el *notebook* `accuracy.ipynb`.
- Establecer la ubicación del conjunto de datos reservado para el testeo y del modelo a utilizar y lanzar todas las celdas del *notebook*.

D.5. Pruebas del sistema

Las diferentes pruebas que se han ido realizando están accesible en el directorio en forma de *notebooks* de Jupyter que pueden ser descargados y ejecutados.

Bibliografía

- [1] Dr Hadeel N Abdullah. Iris recognition using wavelet transform and artificial neural networks. page 13, 2015.
- [2] Johnson Bolívar Arrobo Acaro. Sistema clasificador de iris. Trabajo final de grado, Universidad de Burgos, 2020.
- [3] Aidan Boyd, Adam Czajka, and Kevin Bowyer. Deep learning-based feature extraction in iris recognition: Use existing models, fine-tune or train from scratch?, 2020. Number: arXiv:2002.08916.
- [4] Aidan Boyd, Shivangi Yadav, Thomas Swearingen, Andrey Kuehlkamp, Mateusz Trokielewicz, Eric Benjamin, Piotr Maciejewicz, Dennis Chute, Arun Ross, Patrick Flynn, Kevin Bowyer, and Adam Czajka. Post-mortem iris recognition—a survey and assessment of the state of the art. *IEEE Access*, 8:136570–136593, 2020.
- [5] John G. Daugman. High confidence visual recognition of persons by a test of statistical independence. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 15(11), 1993.
- [6] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [7] Guoyang Liu, Weidong Zhou, Lan Tian, Wei Liu, Yingjian Liu, and Hanwen Xu. An efficient and accurate iris recognition algorithm based on a novel condensed 2-ch deep convolutional neural network. *Sensors*, 21(11):3721, 2021.

- [8] Jus Lozej, Blaz Meden, Vitomir Struc, and Peter Peer. End-to-end iris segmentation using u-net. In *2018 IEEE International Work Conference on Bioinspired Intelligence (IWOBI)*, pages 1–6. IEEE, 2018.
- [9] Jasem Rahman Malgheet, Noridayu Bt Manshor, and Lilly Suriani Affendey. Iris recognition development techniques: A comprehensive review. *Complexity*, 2021:1–32, 2021.
- [10] Maciej Szymkowski, Piotr Jasiński, and Khalid Saeed. Iris-based human identity recognition with machine learning methods and discrete fast fourier transform. *Innovations in Systems and Software Engineering*, 17(3):309–317, 2021.